

Resolução Comentada

Questão 1: Busca Informada (A^*)

Gabarito: B) Apenas I e III são verdadeiras

A afirmação I é correta: o algoritmo A^* é completo e ótimo quando utiliza heurística admissível. A afirmação II é falsa: a busca gulosa não garante solução ótima. A afirmação III é verdadeira: heurísticas consistentes são sempre admissíveis, mas nem toda heurística admissível é consistente.

Complemento: A consistência da heurística impõe $h(n) \leq c(n, a, n') + h(n')$, garantindo que $f(n) = g(n) + h(n)$ não decresce ao longo do caminho. A^* depende profundamente dessa propriedade para evitar reexpansões desnecessárias.

Questão 2: Pooling em CNNs

Gabarito: D) Pooling aumenta o número de parâmetros treináveis da rede

Pooling não possui parâmetros treináveis. Max e average pooling apenas aplicam operações fixas sobre regiões da imagem, reduzindo dimensionalidade e introduzindo invariância a pequenas translações.

Complemento: Pooling tradicional vem sendo substituído em arquiteturas modernas por convoluções com *stride* e *global average pooling* no final da rede.

Questão 3: Softmax

Gabarito: B) A soma de todas as probabilidades de saída será igual a 1

A softmax transforma logits arbitrários em probabilidades:

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}.$$

Todas as outras alternativas descrevem propriedades inexistentes.

Complemento: A softmax é invariante por soma de constantes: $\text{softmax}(z) = \text{softmax}(z + c)$, importante para estabilidade numérica.

Questão 4: Q-Learning

Gabarito: C) A equação de atualização usa o valor máximo de Q no próximo estado

Atualização:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left(r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right).$$

Q-learning é off-policy, não exige ambientes determinísticos e pode ser usado em estados contínuos com aproximadores.

Complemento: O uso do máximo caracteriza aprendizado de uma política ótima mesmo quando a política comportamental é exploratória.

Questão 5: Overfitting em Árvores

Gabarito: C) Aumentar indefinidamente a profundidade

Todas as demais estratégias atenuam overfitting. A profundidade ilimitada amplifica variação e ajusta ruído.

Complemento: Parâmetros típicos: `max_depth`, `min_samples_leaf`, `max_leaf_nodes`. Em modelos ensemble, o controle muda para número de árvores, *subsampling* e *learning rate*.

Questão 6: SVM e o Parâmetro C

Gabarito: B) A margem diminui e o modelo torna-se mais sensível a outliers

C grande penaliza fortemente violações. C pequeno suaviza margem e aumenta regularização.

Complemento: O efeito é um trade-off bias-variance regulado pela intensidade da penalização.

Questão 7: Exploding Gradients em RNNs

Gabarito: C) Gradient clipping

Clipping limita a norma do gradiente e evita instabilidade.

Complemento: Arquiteturas como LSTM e GRU mitigam tanto *vanishing* quanto *exploding gradients*.

Questão 8: K-Means

Gabarito: C) Apenas I e III são verdadeiras

K-means depende da inicialização e exige escolha prévia de K . Ele não garante ótimo global.

Complemento: Métodos de escolha de K : cotovelo, silhouette, informação bayesiana (em GMMs).

Questão 9: Regressão Logística

Gabarito: B) Entropia Cruzada Binária

Loss:

$$L = -[y \log p + (1 - y) \log(1 - p)].$$

Complemento: Minimizar BCE coincide com maximizar a verossimilhança Bernoulli.

Questão 10: Transfer Learning

Gabarito: B) Congelar todas as camadas exceto a de saída

Cenário ideal quando o dataset é pequeno e similar ao domínio original.

Complemento: Etapa posterior opcional: *fine-tuning* parcial das camadas superiores.

Questão 11: Sistemas Especialistas

Gabarito: B) Motor de inferência

É o módulo que aplica regras, resolve conflitos e encadeia inferências.

Complemento: O ciclo clássico envolve agenda de conflitos, seleção de regras e atualização da base de fatos.

Questão 12: Dataset Desbalanceado

Gabarito: D) Ignorar completamente o desbalanceamento

Todas as demais alternativas são técnicas adequadas.

Complemento: Métricas relevantes: F1, AUC-ROC, precision-recall, balanced accuracy.

Questão 13: Gradient Boosting

Gabarito: B) Cada novo modelo corrige erros anteriores

Difere de Random Forest, que treina modelos em paralelo.

Complemento: Iteração típica:

$$F_m(x) = F_{m-1}(x) + \eta h_m(x),$$

onde h_m aproxima o gradiente negativo da loss.

Questão 14: Word Embeddings

Gabarito: B) Rainha

Analogia clássica:

$$\text{rei} - \text{homem} + \text{mulher} \approx \text{rainha}.$$

Complemento: Embeddings capturam relações lineares em atributos como gênero e tempo verbal.

Questão 15: Regularização L1 vs L2

Gabarito: B) L1 produz soluções esparsas

L1 zera pesos; L2 encolhe mas dificilmente zera.

Complemento: Elastic Net combina vantagens de L1 e L2.

Questão 16: Dead ReLU

Gabarito: B) O neurônio entra em “dead ReLU”

Se a combinação linear é sempre negativa, a saída permanece zero e não há gradiente.

Complemento: Variações como LeakyReLU evitam este problema.

Questão 17: EM em GMMs

Gabarito: B) Cálculo das probabilidades posteriores

No passo E calculam-se as responsabilidades:

$$\gamma_{ik} = P(z_k | x_i).$$

Complemento: No passo M atualizam-se médias, covariâncias e pesos das componentes.

Questão 18: Validação Cruzada 5-Fold

Gabarito: C) 800 treino, 200 validação

Cada fold contém 200 exemplos de um total de 1000.

Complemento: A média do desempenho nos 5 folds geralmente é menos enviesada.

Questão 19: GANs

Gabarito: B) Distinguir real de gerado

O discriminador otimiza uma função de classificação binária real vs fake.

Complemento: No equilíbrio teórico, o gerador reproduz a distribuição real e o discriminador retorna 0.5.

Questão 20: Exploration vs Exploitation

Gabarito: B) Exploração testa ações desconhecidas; exploração usa as melhores ações conhecidas

A essência do dilema é o equilíbrio entre descobrir e explorar.

Complemento: Estratégias comuns: ε -greedy, softmax sobre Q, UCB e Thompson Sampling.